

وثيقة التسليم - Olist مشروع مستودع بيانات

المقرر: Data Engineering Assignment

مجموعة البيانات: Olist E-Commerce (Kaggle)

الطالب: وليد عبدالقادر العباسي

المدرّب: الدكتور المهندس أحمد السيد

التاريخ: 30/4/2026

جدول المحتويات

1. نظرة عامة على المشروع
2. الهندسة المعمارية وقرارات التصميم
3. نموذج البيانات
4. ETL خط أنابيب البيانات
5. تحسين الأداء
6. طبقة التقارير
7. التحقق وضمان الجودة
8. مشاكل جودة البيانات التي تمت معالجتها
9. الافتراضات الأساسية والمفاضلات
10. قائمة المخرجات المسلمة
11. كيفية التشغيل
12. الخلاصة

1. نظرة عامة على المشروع

ما تم بناؤه

البرازيلية للتجارة الإلكترونية. يقوم الحل باستيراد البيانات التشغيلية الخام Olist مستودع بيانات متكامل وجاهز للإنتاج لمنصة **Medallion** (فضية → برونزية) وتحويلها عبر هندسة (حوالي 1.5 مليون صف) SQLite من 11 جدول في قاعدة بيانات تحتوي على 11 بعداً و 5 جداول حقائق، محسّنة للاستعلامات التحليلية عالية Kimball بطريقة Star Schema إلى (ذهبية الأداء).

المقاييس الرئيسية

المقياس	القيمة
النظام المصدر	SQLite (جدول، 1,559,764 صف 11)
النظام الهدف	PostgreSQL (olist_olap)
الهندسة المعمارية	Kimball Star Schema + نمط Medallion
جداول الأبعاد	جدول (165,666 صف) 11

المقياس	القيمة
جداول الحقائق	جداول (717,241 صف) 5
مراحل ETL	مراحل (آلية بالكامل) 8
Python عدد ملفات	ملف 13
إجمالي أسطر الكود	سطر ~1,800
فهارس الأداء	B-tree فهرس 20
التحقق الهيكلي	فحصاً - الكل ناجح 29
مقارنة المصدر بالهدف	فحصاً - الكل ناجح 37

الهندسة المعمارية وقرارات التصميم 2.

2.1 لماذا Kimball Star Schema؟

البديل	لماذا تم رفضه
Inmon (3NF)	معقدة متعددة الجداول لكل تقرير. استعلامات أبطأ. أصعب على مستخدمي الأعمال JOINS يتطلب
Wide Flat Table	تكرار هائل للبيانات. مستحيل الصيانة. غير مرن للأسئلة الجديدة
Data Vault	لهذا الحجم من البيانات. تنفيذ معقد بدون فائدة على هذا النطاق Over-engineering

للسبب التالية **Kimball Star Schema**: الاختيار

- أقل = استعلامات أسرع JOINS الأبعاد غير المطابقة تعني
- مفهوم بديهي لمستخدمي الأعمال (الحقائق = أحداث، الأبعاد = سياق)
- BI (Power BI, Tableau, Looker) دعم أصلي في جميع أدوات
- (صف ~1.5M) مناسب لحجم البيانات

2.2 لماذا جداول حقائق متعددة؟

(Grain): لو دمجت كل شيء في جدول حقائق واحد، سنواجه تعارض في الدقة

العملية التجارية	الدقة الطبيعية	عدد الصفوف	لو تم الدمج
المبيعات	order_id + order_item_id	112,650	التقييمات ستتكرر لكل منتج
المدفوعات	order_id + payment_sequential	103,886	الطلبات متعددة الدفعات ستتكرر المبيعات
التقييمات	review_id	99,224	الطلبات متعددة المنتجات ستحصل على تقييمات مكررة
اكتساب البائعين	mql_id	8,000	لكل أعمدة المبيعات NULL قيم
أحداث الطلب	order_id + event_type	393,481	المبيعات ستتضاعف 4 مرات

الاختيار: 5 جداول حقائق منفصلة - كل منها بدقته الصحيحة. لا يوجد عد مزدوج. تحليلات نظيفة

2.3 لماذا Medallion هندسة


الطبقة	الغرض	الفائدة
البرونزية	نسخ خام 1:1 مع <code>_loaded_at</code>	أرشفة تاريخي. لو كان منطق التنظيف فيه أخطاء، نعيد المعالجة من البرونزية بدون إعادة الاستخراج من المصدر
الفضية	منظفة، مدمجة، مرقمة	Star Schema يمكن للمحللين الاستعلام مباشرة للعمل الاستكشافي دون لمس
الذهبية	جاهز Star Schema للأعمال	محسّن للتقارير. مفاتيح بديلة. فهارس أداء


2.4 جميع قرارات التصميم في لمحة

#	القرار	المبرر
1	Kimball Star Schema	BI استعلامات سريعة، مناسبة لأدوات
2	جداول حقائق متعددة (5)	الدقة الصحيحة لكل عملية تجارية
3	Medallion هندسة	تتبع البيانات، إمكانية إعادة المعالجة
4	Dim_Location فصل	مصدر واحد للحقيقة الجغرافية
5	Dim_Lead + seller_key اختياري	(إلى بائع lead من) تحليل كامل لمسار التحويل
6	Fact_Order_Events (Factless Fact)	استعلامات بسيطة لدورة حياة الطلب
7	SCD Type 1	المصدر يفتقر لتاريخ التغييرات
8	Fact_Reviews في product_key عدم وجود	احترام دقة التقييم (لكل طلب، وليس لكل منتج)
9	فهرس أداء 20	أسرع بـ 10-100 مرة JOINS
10	مفاتيح بديلة رقمية	تخزين أصغر بـ 8 مرات، مقارنات أسرع
11	فحص مقارنة 37	تحقق آلي من المصدر إلى الهدف
12	Dim_Time بعد	تحليل أنماط الشراء خلال اليوم

3. نموذج البيانات

3.1 Star Schema نظرة عامة على





3.2 دقة جداول الحقائق (أهم عنصر في التصميم)

عدد الصفوف	ما يمثله الصف الواحد	الدقة (Grain)	جدول الحقائق
112,650	منتج واحد في طلب واحد	<code>order_id + order_item_id</code>	fact_sales
103,886	معاملة دفع واحدة	<code>order_id + payment_sequential</code>	fact_payments
99,224	تقييم عميل واحد	<code>review_id</code>	fact_reviews
8,000	عميل محتمل مؤهل واحد	<code>mql_id</code>	fact_seller_acquisition
393,481	حدث واحد في دورة حياة طلب	<code>order_id + event_type_key</code>	fact_order_events

3.3 جداول الأبعاد

المصدر	المفتاح	عدد الصفوف	البعد
تم توليده (2018-2016)	<code>date_key</code>	1,096	<code>dim_date</code>
تم توليده (0-1439 دقيقة)	<code>time_key</code>	1,440	<code>dim_time</code>
<code>silver.customers</code>	<code>customer_key</code>	99,441	<code>dim_customer</code>
<code>silver.sellers</code>	<code>seller_key</code>	3,095	<code>dim_seller</code>
<code>silver.products</code> + الترجمة	<code>product_key</code>	32,951	<code>dim_product</code>
<code>silver.geolocation</code> (مُجمع)	<code>location_key</code>	19,615	<code>dim_location</code>
<code>silver.leads</code>	<code>lead_key</code>	8,000	<code>dim_lead</code>
قيم فريدة	<code>payment_type_key</code>	5	<code>dim_payment_type</code>
قيم فريدة	<code>order_status_key</code>	8	<code>dim_order_status</code>
ثابت (شراء، اعتماد، إلخ)	<code>event_type_key</code>	5	<code>dim_event_type</code>

المصدر	المفتاح	عدد الصفوف	البعد
قيم فريدة	lead_source_key	10	dim_lead_source

3.4 مصفوفة العلاقات

البعد	fact_sales	fact_payments	fact_reviews	fact_seller_acq	fact_order_events
dim_date	✓ x5	✓	✓ x2	✓ x2	✓
dim_time	✓	-	-	-	-
dim_customer	✓	✓	✓	-	✓
dim_seller	✓	-	-	✓ (اختياري)	✓
dim_product	✓	-	-	-	-
dim_location	✓ x2	-	-	-	-
dim_order_status	✓	-	-	-	-
dim_payment_type	-	✓	-	-	-
dim_lead	-	-	-	✓	-
dim_lead_source	-	-	-	✓	-
dim_event_type	-	-	-	-	✓

[images/star_schema_diagram.png](#) المجموع: 22 علاقة. الرسم الكامل متوفر في

4. ETL خط أنابيب البيانات

4.1 نظرة عامة على خط الأنابيب

main.py (أمر واحد)

```

|— المرحلة 1: الاستخراج (src/extract/migrate.py)
|   SQLite —————> olist_oltp (PostgreSQL)
|   جدول، 1,559,764 صف تم ترحيلها 11
|
|— المرحلة 2: البرونزية (src/transform/bronze/build_bronze.py)
|   olist_oltp —————> olist_olap.bronze
|   الزمني _loaded_at نسخة طبق الأصل + طابع
|
|— المرحلة 3: الفضية (src/transform/silver/build_silver.py)
|   البرونزية —————> olist_olap.silver
|   منظمة، مدمجة، تم تجميع الترميز الجغرافي
|
|— المرحلة 4: بناء الأبعاد (src/transform/gold/build_dimensions.py)
|   11 —————> للأبعاد DataFrame الفضية
|   تم تعيين المفاتيح البديلة

```

- (src/transform/gold/build_facts.py) المرحلة 5: بناء الحقائق
للحقائق DataFrame الفضية + الأبعاد 5
تم استبدال المفاتيح الطبيعية بالمفاتيح البديلة
- (src/load/load_to_gold.py) المرحلة 6: التحميل
DataFrames —————> olist_olap.dimensions + olist_olap.facts
تم إنشاء 20 فهرس أداء
- (src/validate.py) المرحلة 7: التحقق
فحصاً هيكلياً (عدد الصفوف، المفاتيح الفارغة، التكامل المرجعي) 29
- (src/reconciliation/run_reconciliation.py) المرحلة 8: المقارنة
فحص مقارنة بين المصدر والهدف 37

4.2 مجموعة التقنيات المستخدمة

المكون	التقنية	الغرض
اللغة	Python 3.8+	تنفيذ كامل لخط الأنابيب
معالجة البيانات	Pandas	DataFrame تحويلات
الاتصال بالمصدر	SQLite3	olista.sqlite قراءة
الاتصال بالهدف	SQLAlchemy + psycopg2	PostgreSQL عمليات
الإعدادات	python-dotenv	.env متغيرات البيئة من

4.3 خصائص خط الأنابيب

الخاصية	كيف تحققت
قابلية التكرار	قبل الإنشاء DROP IF EXISTS CASCADE جميع الجداول تستخدم python main.py : أمر واحد
Idempotent	في كل مكان if_exists='replace' . تشغيل الخط الأنابيب عدة مرات ينتج نفس النتيجة
معالجة الفشل	tracebacks يلتقط ويعرض جميع الأخطاء مع try/except في main.py
قابلية التوسع	للبيانات الأكبر. المنطق يبقى دون تغيير PySpark/Dask بـ Pandas يمكن استبدال
نمطي	مستقل. تعديل مرحلة لا يؤثر على الأخرى Python كل مرحلة ملف

4.4 هيكل الكود

```
code/
├── main.py                # المنسق الرئيسي
├── requirements.txt       # الاعتماديات
├── .env.example           # نموذج بيانات الاعتماد
├── src/
│   ├── config.py         # الإعدادات والاتصالات
│   ├── extract/migrate.py # المرحلة 1
│   ├── transform/
│   │   └── bronze/build_bronze.py # المرحلة 2
```

```

|   |   | silver/build_silver.py    # المرحلة 3
|   |   | └─ gold/
|   |   |   |   | build_dimensions.py # المرحلة 4
|   |   |   |   | └─ build_facts.py   # المرحلة 5
|   |   | └─ load/load_to_gold.py    # المرحلة 6
|   |   | └─ validate.py             # المرحلة 7
|   |   | └─ reconciliation/
|   |   |   |   | reconciliation_queries.py # تعريفات الاستعلامات
|   |   |   |   | └─ run_reconciliation.py  # المرحلة 8

```

تحسين الأداء. 5

استراتيجية الفهرسة 5.1

تم إنشاؤها على جميع أعمدة المفاتيح الخارجية في جداول الحقائق **B-tree فهرس 20**.

جدول الحقائق	الأعمدة المفهرسة
fact_sales	customer_key, seller_key, product_key, purchase_date_key, delivered_customer_date_key, order_status_key, customer_location_key, seller_location_key (8 فهرس)
fact_payments	customer_key, payment_date_key, payment_type_key (3 فهرس)
fact_reviews	customer_key, review_creation_date_key (2 فهرس)
fact_seller_acquisition	lead_key, seller_key, lead_source_key (3 فهرس)
fact_order_events	customer_key, seller_key, event_date_key, event_type_key (4 فهرس)

تأثير الأداء:

نوع الاستعلام	بدون فهرس	مع فهرس
JOIN fact_sales ↔ dim_customer	مسح كامل للجدول (صف 112K)	بحث بالفهرس (~3 قراءات صفحة)
تصفية بنطاق تاريخي	مسح كامل للجدول	مسح نطاق بالفهرس
GROUP BY مع JOIN	على مسح كامل Hash join	Nested loop فهرس

المفاتيح البديلة 5.2

VARCHAR(32) بدلاً من المفاتيح الطبيعية **INTEGER** جميع الأبعاد تستخدم مفاتيح بديلة.

المقياس	المفاتيح الطبيعية (VARCHAR)	المفاتيح البديلة (INT)
FK التخزين لكل	32 bytes	4 bytes
حجم الفهرس	أكبر	أصغر بـ 8 مرات
JOIN سرعة	أبطأ (مقارنة نصوص)	أسرع (مقارنة أعداد صحيحة)

وحدها FK من التخزين لأعمدة MB المفاتيح البديلة توفر ~15. 112,650 صف 5 × fact_sales: مثال

5.3 تحسينات إضافية

التقنية	الحالة	الفائدة
Materialized Views	جاهزة للتنفيذ	تجميعات يومية محسوبة مسبقاً
Role-Playing Dimensions	مطابقة (dim_date × 11)	جدول واحد يخدم 11 علاقة
Degenerate Dimensions	مطابقة (order_id)	عبر الحقائق بدون بعد إضافي JOINS

6. طبقة التقارير

للاطلاع على [queries/sample_queries.sql](#) الإجابة على جميع أسئلة الأعمال المطلوبة وأكثر. راجع Star Schema يتبع الكامل SQL.

6.1 الأسئلة المطلوبة وطريقة الإجابة عليها

سؤال العمل	الاستعلام	الجدول الرئيسية المستخدمة
كيف تتجه المبيعات عبر الزمن؟	الإيرادات الشهرية مع مقارنة سنوية	fact_sales + dim_date
من هم العملاء الأكثر قيمة؟	أفضل 10 حسب القيمة التراكمية	fact_sales + dim_customer
ما الذي يؤثر على أداء التسليم؟	التأخير حسب الولاية والمنطقة	fact_sales + dim_location
ما هي المنتجات/الفئات التي تدر الإيرادات؟	إيرادات الفئة مع درجات التقييم	fact_sales + dim_product + fact_reviews

6.2 استعلامات تحليلية إضافية (فوق المطلوب)

الاستعلام	القيمة التجارية
سلوك الدفع (الأقساط مقابل قيمة الطلب)	فهم كيف تؤثر خيارات الدفع على الإنفاق
مسار دورة حياة الطلب (من الشراء للتسليم)	تحديد أين تنتسرب الطلبات
مسار اكتساب البائعين حسب القناة التسويقية	تحسين الإنفاق التسويقي
معدل تكرار شراء العملاء	قياس الولاء والاحتفاظ
المبيعات اليومية حسب أيام الأسبوع مقابل العطل	تخطيط التوظيف والحملات
تأثير تأخير التسليم على درجات التقييم	قياس كيف تؤثر اللوجستيات على الرضا
بطاقة أداء أفضل البائعين	تحديد أفضل الشركاء
الإيرادات حسب المنطقة البرازيلية	تخطيط التوسع الجغرافي

7. التحقق وضمان الجودة

7.1 التحقق الهيكلي (29 فحصاً)

الفئة	الوصف	العدد
مقارنة عدد الصفوف	جداول الحقائق تطابق أعداد المصدر الفضي	5
الكشف عن المفاتيح الخارجية الفارغة	(seller_key باستثناء) المفاتيح الأساسية فارغة	18
التكامل المرجعي	لها مفاتيح أساسية مطابقة في الأبعاد FKs جميع	6

اختبار المقارنة (37 فحصاً) 7.2

(olist_olap) والهدف (olist_oltp) يقارن المقاييس المجمعة بين المصدر

الفئة	الفحوصات	ما تتحقق منه
A - عدد الصفوف	6	ETL لا يوجد فقدان للبيانات أثناء
B - المقاييس المالية	5	دقة الإيرادات، الشحن، المدفوعات
C-G - التوزيعات	7	الحالات، أنواع الدفع، درجات التقييم، الفئات، العملاء المحتملين
H-N - متقدم	19	الأحداث، الجغرافيا، التواريخ، المنتجات، الأقساط، التسليم

نتائج التحقق 7.3

=====

تقرير التحقق - 29 فحصاً

=====

جميع الفحوصات ناجحة ✓

=====

=====

ملخص المقارنة - 37 فحصاً

=====

المجموع: 37 | ناجح: 37 | فاشل: 0

الحالة: ✓ المصدر والهدف متطابقان

=====

تم إكمال خط الأنابيب بنجاح

مشاكل جودة البيانات التي تمت معالجتها 8.

#	المشكلة	جدول المصدر	كيف عالجنها
1	إحداثيات بصيغة علمية (-2.354e+01)	geolocation	تحويلها إلى صيغة عشرية صحيحة (-23.54)
2	أسماء مدن غير متناسقة (sao paulo مقابل são paulo)	geolocation	إزالة علامات التشكيل، lowercase: توحيد تقليم المسافات

#	المشكلة	جدول المصدر	كيف عالجنها
3	geolocation صف مكرر في 1,000,163	geolocation	zip_code_prefix ← 19,615 صف فريد
4	أسماء فئات إنجليزية مفقودة	products	الربط مع جدول الترجمة؛ ملء الفارغ بالاسم البرتغالي الأصلي
5	اسم عمود به خطأ إملائي (product_name_lenght)	products	تصحيح الاسم إلى product_name_length
6	تواريخ مخزنة كنصوص	orders, reviews	DATETIME/TIMESTAMP تحويلها إلى صحيح
7	leads_closed في NULL قيم (إلخ، average_stock)	leads_closed	له معنى: العميل لم) NULL الحفاظ على (يتحول بعد
8	صفوف دفع متعددة لكل طلب	order_payments	الحفاظ عليها كصفوف منفصلة (الدقة الصحيحة)

9. الافتراضات الأساسية والمفاضلات

9.1 الافتراضات الأساسية

الافتراض	السبب
يمثل كمية = 1 order_item كل	هيكل البيانات المصدريّة: صف واحد لكل منتج فريد في كل طلب
تاريخ الدفع ≈ تاريخ الشراء	يفتقر إلى طابع زمني صريح للدفع order_payments جدول
الرموز البريدية للترميز الجغرافي تغطي معظم العملاء	من 99,441 عميل (0.3%) لديهم رموز بريدية غير موجودة في 302 geolocation جدول
SCD Type 1 كافٍ	البيانات المصدريّة لا توفر تاريخ تغييرات العناوين

9.2 المفاضلات

المفاضلة	ما كسبناه	ما ضحينا به
جداول حقائق متعددة مقابل جدول واحد	دقة صحيحة، لا عد مزدوج	استعلامات عبر الحقائق تتطلب JOINS
Star Schema مقابل 3 NF	استعلامات سريعة، بسيطة لأدوات BI	بعض تكرار البيانات في الأبعاد
Fact_Order_Events جدول	استعلامات مسار بسيطة، أداء سريع	393 صف تخزين إضافي
الطبقة البرونزية	إمكانية إعادة المعالجة، سجل التدقيق	تخزين إضافي، خط أنابيب أطول
فهرساً 20	أداء استعلامات أسرع 10-100 مرة	تخزين إضافي 10% ~

10. قائمة المخرجات المسلمة

#	المخرج المطلوب	ما سلمناه	الحالة
1	نموذج البيانات (رسم + شرح)	images/star_schema_diagram.png + docs/star_schema_diagram.md + docs/data_dictionary.md	✓
2	تنفيذ ETL/ELT	code/ - 13 ملف Python، 8 مراحل	✓
3	المخطط الهدف (DWH)	docs/data_dictionary.md - 16 جدول موثق بالكامل	✓
4	استعلامات تحليلية نموذجية	queries/sample_queries.sql - 12 استعلام أعمال	✓
5	توثيق القرارات	docs/decisions.md - 12 سجل قرار معماري	✓

مخرجات إضافية (فوق المطلوب)

العنصر	الموقع	الغرض
إثبات تنفيذ الخط الأنابيب	pipeline_output.txt	يثبت نجاح جميع الفحوصات الـ 66
استعلامات المقارنة	queries/reconciliation_queries.sql	استعلام تحقق من المصدر مقابل 18 الهدف
رسم الهندسة المعمارية	images/architecture_diagram.png	تصور كامل لتدفق البيانات
رسم طبقات Medallion	images/medallion_layers.png	مراحل التحويل الثلاث
تعليمات الإعداد	code/README.md	دليل تشغيل خطوة بخطوة

11. كيفية التشغيل

المتطلبات الأساسية

- Python 3.8+
- PostgreSQL 12+

بداية سريعة

```
# الانتقال إلى مجلد الكود 1.
cd code

# تثبيت الاعتماديات 2.
pip install -r requirements.txt

# إعداد بيانات اعتماد قاعدة البيانات 3.
cp .env.example .env
# الخاصة بك (المضيف، المنفذ، المستخدم، كلمة PostgreSQL بمعلومات .env. تعديل
(المرو
```

```
# 4. olist.sqlite مجلد في data/ وضع
# https://www.kaggle.com/datasets/terencicp/e-commerce-dataset-by-olist-as-an-sqlite-database :تحميل من

# 5. تشغيل خط الأنابيب الكامل
python main.py
```

الخرج المتوقع

- المراحل 1-8 تنفذ بالتسلسل
- فحصاً هيكلياً ناجحاً 29/29
- فحص مقارنة ناجحاً 37/37
- الرسالة النهائية: **PIPELINE COMPLETED SUCCESSFULLY**

هيكل المشروع بعد الإعداد

```
Olist_DWH_Project/
├── README.md          # توثيق كامل للمشروع
├── code/              # code/README.md + جميع الأكواد
├── docs/              # ملفات توثيق مفصلة 5
├── images/            # رسوم بيانية احترافية 3
├── queries/           # استعلام تحليلي + 18 استعلام مقارنة 12
└── pipeline_output.txt # سجل تنفيذ ناجح
```

12. الخلاصة

ما تم تسليمه

للتجارة الإلكترونية يقوم بـ Olist حل مستودع بيانات كامل وجاهز للإنتاج لمنصة

1. (صف M جدول، 1.5 11) SQLite استيراد البيانات التشغيلية الخام من
2. (برونزية → فضية → ذهبية) Medallion تحويلها عبر هندسة
3. (بعداً + 5 جداول حقائق 11) Kimball Star Schema نمذجتها كـ
4. تحسينها بـ 20 فهرس أداء ومفاتيح بديلة رقمية
5. التحقق منها بـ 66 فحصاً آلياً (29 هيكلية + 37 مقارنة)
6. توثيق كل قرار وافترض ومفاضلة

نقاط القوة الرئيسية

نقطة القوة	الدليل
نمذجة بيانات صحيحة	حقائق بدقات مختلفة تمنع العد المزدوج 5
خط أنابيب نظيف	نمطي، 8 مراحل محددة جيداً، Idempotent، أمر واحد
جاهز للإنتاج	معالجة أخطاء، تسجيل، فهرس، مفاتيح بديلة

الدليل	نقطة القوة
ADR رسوم بيانية، 12 3 docs، ملفات 5، README،	موثق بشكل شامل

التوافق مع معايير التقييم

كيف تميزنا	المعيار
قراراً معمارياً موثقاً مع البدائل والمبررات 12	التفكير
دقة صحيحة لكل جدول حقائق، 22 علاقة نظيفة، لا عد مزدوج	النمذجة
قابل للتكرار، Idempotent، خط أنابيب نمطي من 8 مراحل	الهندسة
فهرساً، مفاتيح بديلة، أبعاد متعددة الأدوار 20	الأداء
(تعليقات الكود ← docs ← README) توثيق واضح على كل المستويات	التواصل

نهاية وثيقة التسليم